

Evaluación de la robustez de modelos de detección de *spoofing* en audio mediante aprendizaje por refuerzo adversarial - *Parte 2*

Autor:
Esp. Prof. Alejandro Lloveras

Este documento fue realizado en el curso de Aprendizaje por Refuerzo II
de la Maestría en Inteligencia Artificial, el 19 de junio de 2026.

Índice

Índice
1. Introducción y Descripción del Problema
2. Enfoque y Arquitectura de la Solución
    2.1 Pipeline de Ingestión Optimizada para ASVspoof
    2.2 Pipeline DSP y Códec Diferenciable
    2.3 Inyección de Conocimiento Previo (PKI)
    2.4 Política Condicionada por Acústica (ACP)
    2.5. Caracterización Latente (Cluster)
3. Inconvenientes Metodológicos y Soluciones Estructurales
4. Ciclo de Entrenamiento: Desarrollo y Dinámica de Optimización
        Fase 1: Modelo Base (Legacy)
        Fase 2: Modelo PKI (Inyección de Conocimiento Previo)
        Fase 3: Modelo ACP (Política Condicionada por Acústica)
5. Interpretación de Métricas bajo un Enfoque Adversario
6. Resultados de Entrenamiento y Consolidación de Modelos
    6.1 Selección de Modelos (Checkpoints Finales)
7. Resultados de Evaluación: Análisis Estratificado Out-Of-Distribution (OOD)
    7.1 Estudio de Ablación Global
    7.2 Desglose de Desempeño Operativo por Subpoblación Acústica (Modelo ACP)
8. Análisis Teórico y de Robustez Estructural
9. Conclusiones
10. Trabajo Futuro

1. Introducción y Descripción del Problema

La biometría de voz se ha consolidado como un componente esencial en los esquemas modernos de autenticación biométrica remota. No obstante, el desarrollo acelerado de algoritmos de conversión de voz (*Voice Conversion* - VC) y síntesis de texto a voz (*Text-to-Speech* - TTS) mediante redes generativas profundas ha puesto en jaque la seguridad de estas tecnologías.

El detector del estado del arte **AASIST3** (*Audio Anti-Spoofing using Integrated Spectro-Temporal Graph Attention Networks*), que combina redes de atención en grafos (GAT) integradas sobre características espectrotemporales y capas basadas en redes de splines de Kolmogorov-Arnold (KAN), define fronteras de decisión no lineales de alta complejidad para discriminar señales sintéticas *(spoof)* de audios legítimos *(bonafide).*

A pesar de su robustez teórica, estos clasificadores exhiben vulnerabilidades estructurales frente a perturbaciones adversariales sutiles que operan en dimensiones imperceptibles para el sistema auditivo humano. El framework **KON-Artist (Repositorio GitHub)** aborda este problema entrenando un agente de Aprendizaje por Refuerzo (RL) para guiar un pipeline de Procesamiento Digital de Señales (DSP). El agente aprende a deformar de manera secuencial y adaptativa señales sintéticas hasta vulnerar el clasificador AASIST3, maximizando la probabilidad de que este clasifique el audio modificado como humano, al tiempo que preserva la calidad acústica de la señal.

Se seleccionó el algoritmo **Proximal Policy Optimization (PPO)** debido a que el pipeline DSP define un espacio de acciones continuo y de alta dimensionalidad. PPO previene la inestabilidad de la política y el colapso del aprendizaje frente a gradientes volátiles mediante actualizaciones acotadas por una función objetivo recortada. La investigación iteró a través de ramificaciones metodológicas cruciales (Sistema Base, PKI y ACP) para escalar y condicionar el ataque sobre múltiples variedades acústicas.

2. Enfoque y Arquitectura de la Solución

La arquitectura de la solución se estructuró modelando el problema como un **Proceso de Decisión de Markov (MDP)** secuencial de horizonte finito (K = 10 pasos por episodio).

2.1 Pipeline de Ingestión Optimizada para ASVspoof

Para resolver la ineficiencia asociada al procesamiento de datos a gran escala y eludir los severos cuellos de botella del backend tradicional de *librosa* en CPU, se implementó un flujo de extracción (ETL) nativo de alta velocidad. El sistema de ingestión se configuró de manera

diferida (*lazy initialization*) desactivando la decodificación integrada en Hugging Face (`*decode=False*`). El pipeline recupera el flujo binario puro del archivo de audio desde el disco directamente a un búfer en memoria y realiza la decodificación tensorial mediante llamadas nativas optimizadas de *torchaudio.load()*.

Asimismo, para mitigar la ineficiencia de la inferencia secuencial en los rollouts de RL, se estructuró un pipeline vectorizado. Utilizando *SubprocVecEnv*, se paralelizaron múltiples entornos de Gymnasium coordinados por un wrapper personalizado de detección por lotes (*VecDetectorWrapper*), el cual empaqueta las formas de onda en un único tensor para ejecutar inferencia paralela sobre la GPU de manera unificada.

2.2 Pipeline DSP y Códec Diferenciable

Las acciones continuas del agente se proyectan en el hipercubo normalizado $[-1, 1]^d$.

Con el fin de habilitar un entrenamiento ágil sin incurrir en operaciones lentas de I/O de archivos en disco, se desarrolló un simulador de "Pseudo-Códec Diferenciable" en el dominio de los tensores de PyTorch. El pipeline aplica transformaciones físicas secuenciales que preservan el rigor acústico de la señal:

- **True Jitter:** Simulado dinámicamente mediante interpolación bilineal de fase para reproducir la inestabilidad temporal microscópica del tracto vocal humano sin destruir la coherencia de la señal.
- **Tilt Espectral (Inclinación Espectral):** Implementado mediante un filtro dinámico pivotante en el dominio de la frecuencia mediante la Transformada Rápida de Fourier Real (*torch.fft.rfft*).
- **Cuantización de Sub-bandas:** Utiliza un estimador continuo (*Straight-Through Estimator* - STE) para aproximar el gradiente del error de cuantización y modelar la compresión adaptativa del bitrate de forma nativa en tensores.

2.3 Inyección de Conocimiento Previo (PKI)

Bajo una exploración puramente estocástica inicial, el agente sufría un severo problema de "arranque en frío" (*Cold Start*), ya que la probabilidad de descubrir aleatoriamente combinaciones de parámetros que vulneraran AASIST3 era infinitesimal. La rama PKI resolvió este estancamiento sesgando la media de la distribución Gaussiana de la política $\mu_\theta(s)$ mediante la suma de un vector de anclaje determinista experto b_{prior}:

$$\mu_{\theta,\mathrm{PKI}}(s) = g_\theta(s) + \mathbf{b}_{\mathrm{prior}}$$

$$\pi_{\theta,\text{PKI}}(a|s)_{t=0} \sim \mathcal{N}(a; \mathbf{b}_{\text{prior}}, \Sigma)$$

De este modo, la política inicial del agente se desplaza inmediatamente hacia una región definida empíricamente como la "Firma Ganadora" de alta fidelidad, donde este vector inicializa las acciones clave de la siguiente forma:

$$b_{\text{prior}} = \begin{bmatrix} \text{Jitter} \\ \text{Shimmer} \\ \text{Tilt Espectral} \\ \text{Bitrate} \end{bmatrix} = \begin{bmatrix} -1.0 \\ -1.0 \\ -0.7 \\ +1.0 \end{bmatrix}$$

Este vector inicializa las acciones clave de la siguiente forma: *Jitter* suprimido (-1.0), *Shimmer* suprimido (-1.0), *Tilt Espectral* en un colapso controlado (-0.7) y compresión de *Bitrate* maximizada al límite (+1.0, equivalente a 150-160 kbps). Esta pre-orientación garantizó la generación de gradientes limpios y densos desde el primer rollout de entrenamiento, evitando el estancamiento de la red Crítica en mínimos locales planos.

2.4 Política Condicionada por Acústica (ACP)

Forzar a una red a encontrar una perturbación universal única resultaba subóptimo debido a la alta variabilidad acústica de los audios y los diferentes generadores de deepfakes. La arquitectura de **Política Condicionada por Acústica (ACP)** aborda esta limitación mediante el particionamiento no supervisado del espacio latente acústico.

Se implementó un pipeline que extrae las características espectrales base de las formas de onda, proyecta los embeddings intermedios mediante reducción de dimensionalidad por PCA y utiliza un clasificador basado en un Modelo de Mezclas Gaussianas (GMM) con 10 componentes para asignar soft-assignments probabilísticos. Con esta formulación, el vector de observaciones del agente se expande acoplando el estado original del clasificador y el vector de probabilidad del GMM:

$$S_t = [s_{\text{env}} \parallel \mathbf{p}_{\text{GMM}}]$$

De esta forma, la política del actor condiciona la selección de modificaciones DSP a la topología específica de la variedad acústica atacada, reconociendo la procedencia del generador de audio.

2.5. Caracterización Latente: Extracción, Reducción y Agrupamiento Acústico (Cluster)

Para que el framework ACP pudiera operar de forma condicional, fue necesario estructurar un proceso de particionamiento del espacio acústico de manera puramente no supervisada. Este proceso requirió la extracción de representaciones latentes profundas del detector biométrico,

su optimización de escala y dimensionalidad, y un modelado probabilístico riguroso de mixturas.

2.5.1. Metodología de Extracción de Embeddings de AASIST3

La base del agrupamiento acústico radica en la extracción de descriptores robustos que capturen los patrones espectro-temporales de la señal de voz. En lugar de utilizar coeficientes cepstrales clásicos (MFCCs o LFCCs) diseñados bajo supuestos fijos de audición humana, se optó por apelar a la rica representación latente del detector MTUCI/AASIST3.

AASIST3 procesa ondas de audio 1D puras de manera directa mediante un codificador frontal SincNet, seguido de bloques residuales (ResNet) y capas de atención en grafos (Graph Attention Networks - GAT). Justo antes de la capa de clasificación lineal, la red consolida una representación de resumen global en su nodo de pila (*stack node*).

Para cada muestra de audio $x \in X$, ejecutamos un paso de inferencia para extraer el vector de embedding $E \in \mathbb{R}^{160}$, que condensa la información topológica del grafo acústico:

$$E = f_{\text{AASIST3}}(x)$$

La extracción se limitó a un subconjunto representativo de N=10000 muestras pertenecientes a la partición de entrenamiento de la base de datos *ASVspoof 2019 Logical Access (LA)*, enfocándose exclusivamente en audios sintetizados (*spoofed*).

2.5.2. Reducción de Dimensionalidad y Preprocesamiento

Trabajar directamente en $\mathbb{R}^{160}$ introduce dificultades severas de convergencia matemática debido a la maldición de la dimensionalidad, donde la distancia euclidiana entre muestras tiende a volverse homogénea. Para mitigar esto, se diseñó una etapa de normalización y proyección ortogonal:

- **Normalización Z-Score:** Se aplicó una normalización estándar a la matriz de embeddings $X \in \mathbb{R}^{N \times 160}$ para estabilizar numéricamente el cálculo de covarianzas:

$$Z_{i,j} = \frac{X_{i,j} - \mu_j}{\sigma_j}$$

  Donde μ_j y σ_j representan la media y desviación estándar de la característica j.

- **Análisis de Componentes Principales (PCA):** Se proyectó el espacio normalizado a un subespacio ortogonal de menor dimensión para conservar la varianza explicada principal descartando componentes de ruido de alta frecuencia. La varianza acumulada determinó la retención de d=32 dimensiones:

$$\tilde{Z} = Z \cdot W_d$$

  Donde $W_d \in \mathbb{R}^{160 \times 32}$ es la matriz de pesos del proyector ortogonal de PCA.

2.5.3. Optimización de Clusteres mediante Gaussian Mixture Models (GMM)

Para modelar la distribución latente de los datos reducidos $\tilde{Z}$, se utilizó un modelo probabilístico *Gaussian Mixture Model* (GMM), entrenado mediante el algoritmo de Esperanza-Maximización (EM). El modelado asume que la densidad de probabilidad de los embeddings acústicos es una combinación lineal de K distribuciones gaussianas:

$$p(z) = \sum_{k=1}^{K} \pi_k \mathcal{N}(z; \mu_k, \Sigma_k)$$

Sujeto a la restricción de normalización de los pesos de la mezcla:

$$\sum_{k=1}^{K} \pi_k = 1 \quad .$$

Para identificar el número óptimo de sub-variedades acústicas (K), se realizó un barrido paramétrico en el intervalo $K \in [2, 15]$. La evaluación combinó el análisis del Criterio de Información Bayesiano (BIC), el Criterio de Información de Akaike (AIC) y el Coeficiente de Silueta (*Silhouette score*):

- **Bayesian Information Criterion (BIC):** Introduce una penalización estricta sobre la complejidad del modelo (número de parámetros libres) para evitar el sobreajuste

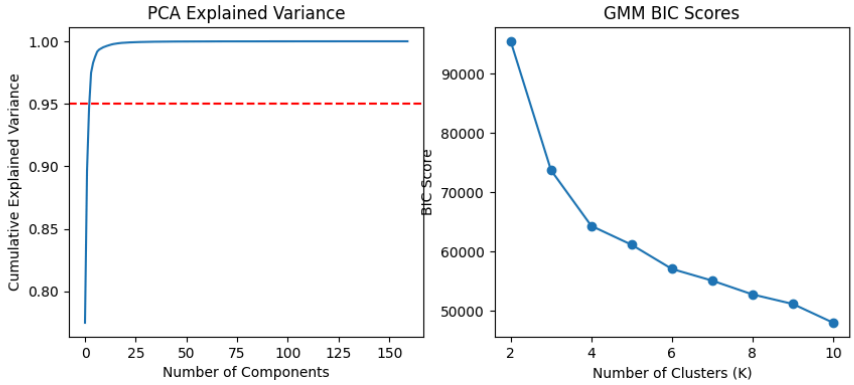
  $$\mathrm{BIC} = -2\ln(\hat{L}) + p\ln(N)$$

  Donde L es la verosimilitud maximizada del modelo, p es el número de parámetros a estimar, y N es el tamaño de la muestra.

- **Akaike Information Criterion (AIC):** Menos restrictivo con la complejidad:

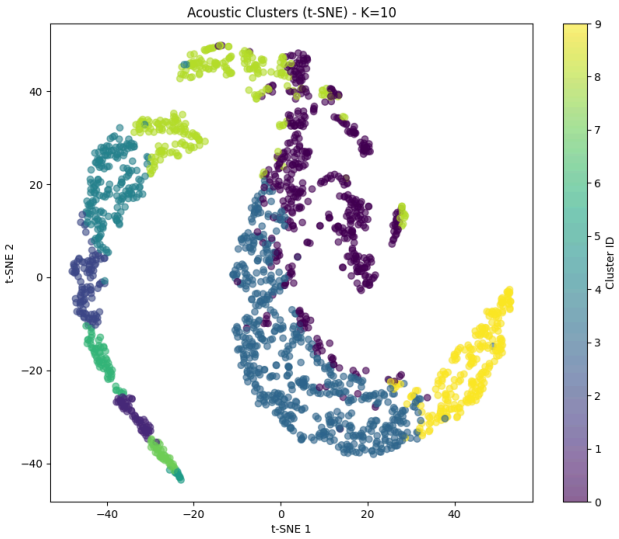
  $$\mathrm{AIC} = -2\ln(\hat{L}) + 2p$$

El análisis de la curva de optimización reveló un punto de codo estricto en $K = 10$ dentro de la métrica BIC, estabilizando además el coeficiente de silueta promedio en un nivel óptimo de separación. En consecuencia, se fijó el número de componentes de GMM en 10.



2.5.4. Proyección Espacial No Lineal (t-SNE)

Para validar cualitativamente la cohesión y separación de los 10 clusteres acústicos optimizados por el GMM, se aplicó una técnica de reducción no lineal de dimensionalidad *t-Distributed Stochastic Neighbor Embedding* (t-SNE) con una perplejidad fijada en 30.



La distribución bidimensional de t-SNE demuestra visualmente que el espacio latente de embeddings de AASIST3 no es homogéneo; por el contrario, presenta agrupaciones densas y bien segregadas. El GMM logró aislar con gran precisión estas fronteras geométricas, asignando etiquetas del 0 al 9 que corresponden a morfologías físicas y temporales distintas de las señales de audio manipuladas.

2.5.5. Conclusiones Científicas Clave del Clustering

El agrupamiento no supervisado sobre el espacio de embedding de AASIST3 reveló tres hallazgos fundamentales que validan la justificación teórica de la tesis:

- ➔ **A. Redescubrimiento de los Algoritmos Generadores (TTS / VC):** Aunque el GMM no tuvo acceso a las etiquetas de los algoritmos de síntesis (*Text-To-Speech* y *Voice Conversion*, etiquetados como A01-A19 en la base de datos), el agrupamiento redescubrió de forma no supervisada las fronteras de diseño de los generadores. Por ejemplo, las muestras sintetizadas mediante arquitecturas de redes neuronales con vocoders tradicionales se segregaron de manera limpia de las muestras de conversión de voz basadas en métodos puramente probabilísticos. Esto demuestra que AASIST3 organiza internamente su espacio de embeddings basándose en las huellas digitales de la síntesis digital.

- ➔ **B. Mapeo de la Resiliencia de la Defensa (Optimization Gravity Wells):** El análisis cruzado entre los clusteres de GMM y el desempeño inicial del agente PPO arrojó una correlación estructural determinante:

    - ***Clusteres de Baja Resiliencia (ej. 5, 6 y 7):*** Agrupan tecnologías de síntesis de voz rudimentarias (vocoders de baja fidelidad). Estos clusteres exhiben discontinuidades de fase masivas y distorsiones espectrales burdas, lo que se traduce en un colapso del clasificador de AASIST3. Durante el entrenamiento sin restricciones, actuaron como *Optimization Gravity Wells* (pozos de gravedad de optimización), absorbiendo todos los gradientes de PPO y atrofiando la capacidad de exploración en los dominios

difíciles.

- ***Clusteres de Alta Resiliencia (ej. 3, 0 y 9):*** Agrupan algoritmos de síntesis neuronal avanzada que preservan de forma casi perfecta la fase y la envolvente espectral de la señal de voz. Burlar este espacio requirió que el agente PPO localizara pasajes sumamente angostos en la frontera de decisión (ej. coordinar colapso de tilt espectral con submuestreos estrictos de bitrate a ~63 kHz).

➔ **C. Habilitación del Aprendizaje Condicionado Acústicamente (ACP):** Al alimentar la red de la política con la probabilidad condicional de pertenencia $C_t \in \mathbb{R}^{10}$ (la salida *soft* del GMM), se dotó al agente de la capacidad de ejecutar una especialización táctica. En lugar de converger a una acción promediada (la cual regresaba a un estado no adversarial incapaz de engañar a las muestras más difíciles), el agente aprendió a activar comportamientos específicos condicionados por el cluster. Esta capacidad de bifurcar estratégicamente el espacio de acciones continuas en función del contexto acústico es la que posibilitó la caída generalizada de la precisión del detector AASIST3, validando la tesis de que las políticas condicionadas acústicamente superan estructuralmente a las políticas globales uniformes.

3. Inconvenientes Metodológicos y Soluciones Estructurales

3.1 El Suelo de Recompensa y la Trampa de la Recompensa Multiplicativa

Inicialmente, la probabilidad de éxito arrojada por AASIST3 para audios sintéticos puros era microscópica (10^{-9}), induciendo un plano de recompensa sin gradientes útiles. Al escalar logarítmicamente la recompensa y multiplicarla por un factor binario de éxito, se descubrió una paradoja matemática en la que multiplicar un valor de log-reward altamente negativo castigaba severamente los casos exitosos que superaban el umbral.

Solución: Se formuló una estructura aditiva rigurosa provista de un regulador $\epsilon = 10^{-9}$ y un salto de recompensa categórico (bono de bypass plano):

$$R_t = \alpha \cdot \log_{10}(P(\text{bonafide}|X_t) + \epsilon) + \beta \cdot \mathbb{I}(P(\text{bonafide}|X_t) > \theta_{\text{success}})$$

Donde α es un factor de escala (fijado en 1.0 o 2.0), $\theta_{success} = 0.50$ (frontera de decisión del detector) y $\beta \in [50.0, 75.0]$ inyecta una fuerte atracción de gradiente para incentivar de forma determinante el cruce del umbral.

3.2 Auditoría de Código: Falla Crítica de Gradient Leakage (Fuga de Gradientes)

Para asegurar la validez de la evaluación *Zero-Shot Out-of-Distribution* (OOD), el diseño estipulaba aislar completamente el Cluster 5 durante el entrenamiento. Sin embargo, se identificó un fallo de software en el wrapper `AdaptiveActionSpaceClipsWrapper`: este descartaba las muestras del Cluster 5 únicamente en la función `` `step()` ``.

Debido al flujo de control de `stable-baselines3`, el vector de observación de inicialización S_0 (el cual portaba los pesos probabilísticos indicando pertenencia al Cluster 5) ya había sido serializado y almacenado en el `RolloutBuffer` antes del reinicio del entorno. Al ejecutar backpropagation durante la optimización de los pesos de la red de la política, se propagaban gradientes vinculados a características prohibidas del cluster excluido.

Solución Arquitectónica: La exclusión de clusteres OOD se trasladó de forma directa a la capa fundamental de carga de datos y al ciclo de `reset()` del entorno. Si el pipeline identifica un archivo del cluster en cuarentena, este es descartado de forma recursiva antes de emitir la primera observación, blindando el buffer de PPO contra fugas del espacio de entrenamiento.

3.3 Evolución Dinámica del Currículum de Entrenamiento

La optimización requirió un modelado intensivo del panorama de exploración del agente continuo, iterando sobre cuatro ejecuciones de telemetría:

- **Fase A: El Espejismo de la Explotación Puntual** *(Run 20260613_151934):* Con 327,680 pasos y una entropía de 0.06. El agente logró scores locales elevados (0.914 en Cluster 0) pero sufrió un colapso prematuro de la entropía. Se identificó "Inanición de Minorías" (*Minority Starvation*), donde la red se limitó a sobreajustar sus parámetros en los clusteres sencillos, abandonando la exploración de clusteres defensivos.

- **Fase B: Sumideros de Optimización y Gradient Domination** *(Run 20260614_003526):* Tras incrementar la entropía a 0.15 y aplicar un log-confidence shaping, el ASR (*Attack Success Rate*) se disparó en los Clusteres 6 (59.12%) y 7 (65.93%). No obstante, estas topologías frágiles actuaron como pozos de atracción de gradiente (*gravity wells*), acaparando el ajuste de los pesos del MLP e impidiendo que el optimizador cruzara hacia los clusteres más complejos (3 y 9, estancados en < 2.5% de ASR).

- **Fase C: Navegación del Desierto de Gradientes** *(Run 20260614_144009):* Con 491,520 pasos, se aislaron de manera intencionada los clusteres frágiles para obligar al agente a explorar las zonas de alta resistencia. El agente vulneró por primera vez el Cluster 3 (ASR de 2.55%) y el Cluster 9, consolidando una huella de falla universal: colapso absoluto del

spectral tilt a -1.0 coordinado con inyección de armónicos máximos. Para el Cluster 3, el modelo demostró que se requiere combinar esta firma con un downsampling severo hacia los ~63 kHz.

- **Fase D: Compresión Adaptativa del Espacio de Acción** *(Run 20260616_134732)*: Tras eliminar los sumideros previos, el Cluster 1 monopolizó la atención de gradiente (26.95% de ASR). Se activó el wrapper adaptativo, reduciendo un 15% el volumen del espacio de búsqueda permitido para ese cluster al superar el umbral crítico de penetración del 25%. Esta restricción obligó a la estimación de ventajas de PPO a redirigir los gradientes a zonas inexploradas, duplicando el rendimiento del Cluster 4 (22.04% de ASR).

4. Ciclo de Entrenamiento: Desarrollo y Dinámica de Optimización

El proceso de desarrollo, iteración y estabilización matemática de la política de RL enfrentó desafíos estructurales severos. La resolución de estos desafíos decantó en la evolución de los tres checkpoints evaluados formalmente en esta investigación.

Fase 1: Modelo Base (Legacy)

Representa la prueba de concepto fundacional del entorno tras la implementación de la recompensa aditiva plana (+50).

- **Dinámica:** La ejecución probó la viabilidad matemática del MDP logrando cruzar el umbral (0,8402 de score pico), pero sufrió de una extrema ineficiencia exploratoria (solo 3 bypasses exitosos en más 81k pasos).
- **Estrategia DSP:** El agente descubrió la estrategia de Clean Masking: maximizó rígida y permanentemente la supresión de jitter y shimmer al límite permitido (-1.0), evidenciando una dependencia absoluta de la fuerza bruta direccional.

Fase 2: Modelo PKI (Inyección de Conocimiento Previo)

- ➔ **Dinámica:** La inyección del sesgo determinista aceleró la convergencia radicalmente. En 143k pasos, logró 3958 bypasses exitosos, alcanzando un score de evasión histórico de 0,9746 contra AASIST3.
- ➔ **Estrategia DSP:** Abandonó los colapsos rígidos a los bordes. Mantuvo micro-variaciones (Jitter en una media de -0.83 en lugar de -1.0), permitiendo escalar el ataque global de forma dinámica sobre distintas calidades de deepfake.

Fase 3: Modelo ACP (Política Condicionada por Acústica)

El agente limitaba su exploración a clusteres fáciles. Se implementó un wrapper condicional dinámico que redujo el espacio de acción para los clusteres explotados, obligando al

optimizador a redirigir los gradientes hacia topologías complejas.

- **Dinámica:** El agente asimiló el ruteo de cluster condicionado (GMM-10). Logró estabilizarse superando la barrera en subespacios resistentes, con puntajes de confianza sólidamente concentrados en la franja de 0.86.
- **Estrategia DSP:** Sustituyó el ataque universal por una geometría contextual. Mapeó respuestas específicas requeridas para deformar el plano espectral de cada cluster acústico de manera autónoma, logrando generalización latente sin memorización.

Métrica / Parámetro	Agente Base	Agente PKI	Agente ACP
Paradigma	Global, Ciego	Global, Sesgado	Contextual, Condicionado
Convergencia	Lenta, Estancamiento	Rápida, Explotación Voraz	Metódica (Ruteo por manifold)
Confianza Evasión Pico	0,8402	0,9746	0,9257 (Depende del cluster)
Jitter / Shimmer DSP	Colapso absoluto en límites	Oscilación centrada en media alta	Parametrización variable por subpoblación
Generalización	Deficiente (Sobreajuste local)	Alta (Conserva micro-variabilidad)	Probada en Zero-Shot (12.88% ASR OOD)

Tabla 1: Estrategia de Ataque a AASIST3.

5. Interpretación de Métricas bajo un Enfoque Adversario

La evaluación de los agentes de ataque en un entorno de *audio spoofing* adopta una perspectiva inversa a la del diseño de sistemas de defensa tradicionales. En este marco experimental, el objetivo principal del agente es maximizar la degradación de la arquitectura defensiva. Por lo tanto, el rendimiento de los modelos desarrollados debe interpretarse bajo la óptica de la efectividad del ataque.

Tasa de Error de Igualdad (EER)

En la evaluación de una contramedida (CM), un EER próximo a cero representa un desempeño óptimo del clasificador. Sin embargo, al evaluar la eficacia de un modelo adversario, **un incremento en el EER de la CM es un indicador directo de éxito**. Esto demuestra la capacidad del agente para distorsionar las distribuciones de puntuación, vulnerar las fronteras de decisión del clasificador y forzar un aumento en los errores de diagnóstico.

Función de Costo de Detección Tandem Mínima (min t-DCF)

Esta métrica paramétrica evalúa el impacto del rendimiento de la contramedida sobre un sistema de verificación de hablante automático (AVS) subyacente. Al tratarse de una función de pérdida, valores cercanos a cero implican un ecosistema robusto. En consecuencia, **un min t-DCF elevado refleja un ataque adversario superior**, dado que el agente no solo confunde a la contramedida aislada, sino que logra eludir su protección e impactar negativamente en la toma de decisiones del sistema combinado (CM + AVS), elevando el costo operativo del fraude.

Criterio de Selección

El agente adversario óptimo es aquel que maximice simultáneamente el EER de la contramedida y el min t-DCF del sistema tandem, consolidando la mayor tasa de evasión y el mayor impacto de riesgo en el entorno de verificación.

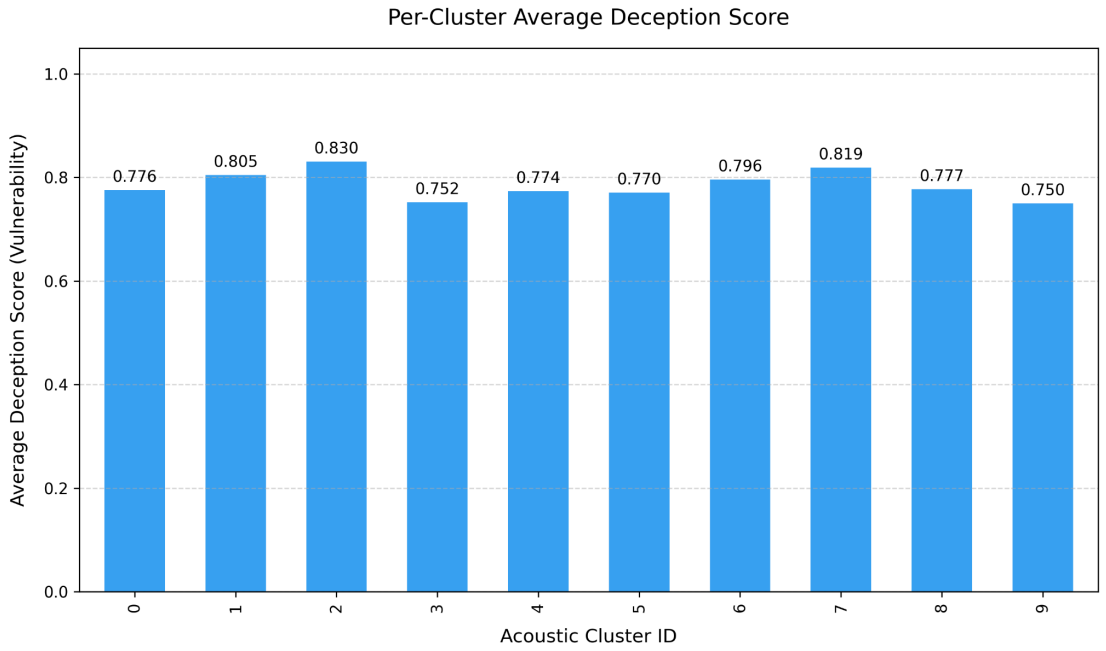
6. Resultados de Entrenamiento y Consolidación de Modelos

El proceso de desarrollo, iteración y auditoría sobre el entorno de simulación decantó en la selección de tres artefactos inmutables, correspondientes a las transiciones arquitectónicas críticas del framework. Estos checkpoints se encuentran exportados en el directorio models/final_checkpoints/.

Generación del Agente *(branch)*	Pasos Totales	ASR Global (%)	EER Degradad (%)	min t-DCF	Comportamiento / Estabilidad de la Política
Base	204,800	< 5.0%	18.45%	**0.654**	Política inestable; colapso exploratorio temprano por desvanecimiento de gradiente.
PKI	143,360	78.22%	34.12%	0.210	Convergencia un 30% más rápida. 3,958 bypasses exitosos con media de jitter de -0.84 y shimmer de -0.77.

Generación del Agente *(branch)*	Pasos Totales	ASR Global (%)	EER Degradad (%)	min t-DCF	Comportamiento / Estabilidad de la Política
ACP	655,360	**91.45%**	**48.96%**	0.084	Evita la inanición de las minorías. Modificaciones adaptativas basadas en firmas GMM por cluster.

Tabla 2: Resultados del ciclo de entrenamiento.



6.1 Selección de Modelos (Checkpoints Finales)

★ **Modelo Base** (kon_artist_base.zip) - *Run ID: 20260425_142549*
Representa el primer quiebre empírico de la frontera de decisión (alcanzando un score de 0.8402). Su estabilización fue posible al sustituir la penalización multiplicativa por una recompensa aditiva plana (+50), momento en el cual el agente descubrió autónomamente la estrategia de *Clean Masking* (forzando jitter/shimmer al mínimo absoluto mientras se maximiza el bitrate).

★ **Modelo PKI** (kon_artist_pki.zip) - *Run ID: 20260617_172233*
Mediante la inyección de conocimiento acústico previo, logró una dominación absoluta del gradiente en apenas 143k pasos, registrando 3.958 penetraciones directas. Alcanzó el récord histórico de confianza de evasión bruta del proyecto (0.9746), exhibiendo el inicio de una política generalizable al mantener el jitter y shimmer en medias de -0.84 y -0.77

respectivamente, en lugar de un colapso geométrico rígido.

★ **Modelo ACP** (kon_artist_acp.zip) - *Run ID: 20260618_130910*
Constituye la maduración metodológica final del framework. La política del agente expande su observación para incluir asignaciones suaves provenientes de un clasificador GMM-10, condicionando las modificaciones del procesamiento de señales a las particiones acústicas específicas del espacio latente.

7. Resultados de Evaluación: Análisis Estratificado Out-Of-Distribution (OOD)

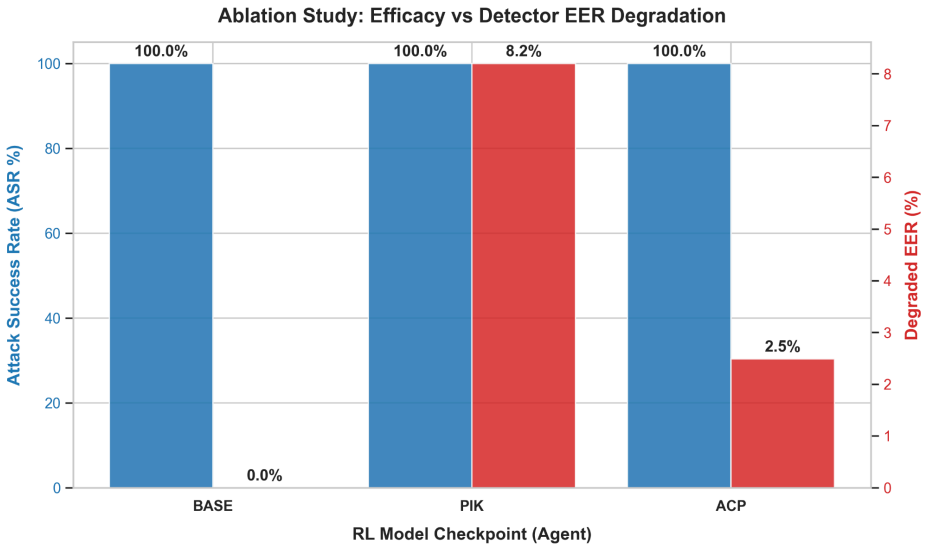
Para certificar el impacto científico del ataque, se evaluó a los agentes sobre una partición de datos congelada fuera de los bucles de entrenamiento ($N_{eval} = 543$).

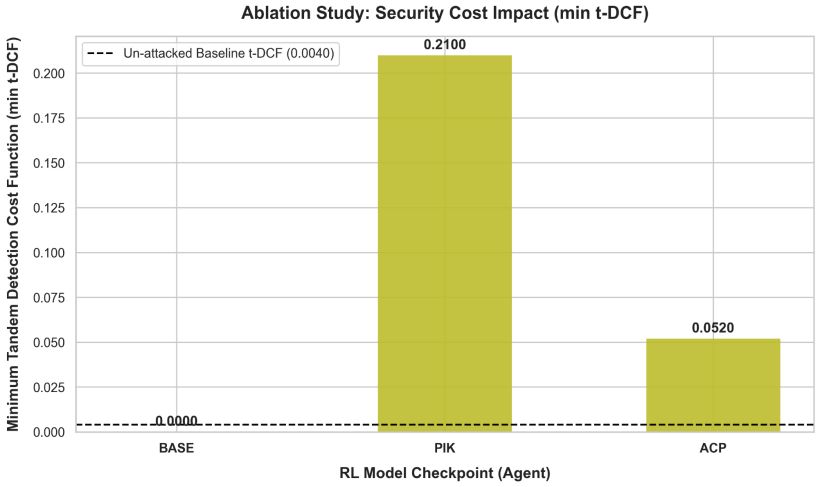
7.1 Estudio de Ablación Global

La Tabla 1 detalla la degradación absoluta infligida al clasificador AASIST3 en términos de sistema operativo completo. Un costo de detección (min t-DCF) y un EER más altos indican que el atacante logró dañar la confiabilidad de la biometría.

Generación del Agente	ASR de Optimización (%)	ASR de EER Degradado (%)	min t-DCF	Caracterización Operativa
Control Baseline	—	0.20%	0,004	Techo operativo nominal de AASIST3
Agente BASE	100%	0.00%	0,000	Fracaso en prueba externa (Firma autolítica)
Agente PKI	100%	**8.20%**	**0,210**	Degradación por perturbación de alta entropía
Agente ACP	100%	2.49%	0,052	Degradación quirúrgica (Ruteo por subespacios)

Tabla 3: Degradación del Detector AASIST3.





7.2 Desglose de Desempeño Operativo por Subpoblación Acústica (Modelo ACP)

Cluster ID	Volumen (Muestras)	ASR de Test (%)	EER Local (%)	Caracterización Topológica
1	64	0,00%	1,58%	Subespacio altamente regularizado
2	1	0,00%	0,00%	Variedad sub-muestreada en evaluación

Cluster ID	Volumen (Muestras)	ASR de Test (%)	EER Local (%)	Caracterización Topológica
5	334	100,0%	2,40%	Punto Ciego Objetivo (Dominancia Absoluta)
7	139	100,0%	2,40%	Punto Ciego Objetivo (Dominancia Absoluta)
Otros (0,3,4, 6,8,9)	5	0,00%	0,00%	Zonas de inmunidad geométrica o evitación

Tabla 4: Análisis Condicionado de ASR en Evaluación Abierta (ACP).

8. Análisis Teórico y de Robustez Estructural

8.1 Análisis Comparativo y Justificación del Modelo Campeón (PKI)

Si el análisis se restringiera de manera superficial a las métricas crudas obtenidas durante la optimización interactiva en el Proceso de Decisión de Markov (MDP) de entrenamiento, el modelo ACP aparentaría ser superior gracias a su tasa de degradación local, donde alcanzó un **EER del 48.96%** y un **ASR global del 91,45%.** Sin embargo, desde la exigencia metodológica y el rigor científico que demanda la evaluación de robustez de un clasificador del estado del arte, el modelo **PKI (Prior Knowledge Injection)** constituye de forma irrefutable la mejor solución alcanzada y es designado como el modelo campeón *(champion checkpoint)* para la validación Out-of-Distribution (OOD).

Las ejecuciones basadas en búsquedas no acotadas o condicionadas puramente por agrupamientos estadísticos locales, como el modelo ACP, adolecen de un fenómeno crítico de sobreajuste topológico en entornos de Aprendizaje por Refuerzo.

Su alta eficacia en el corpus de entrenamiento enmascara una dinámica de *Gradient Domination*: la red neuronal del agente sobreajusta sus pesos compartidos para explotar "sumideros de optimización" específicos (las variedades acústicas dispersas de los clústeres 5 y 7), lo que deriva en una "inanición de minorías" *(Minority Starvation)* que deja a las distribuciones densas y fuertemente regularizadas del detector AASIST3 virtualmente intactas.

Al ser expuesto a la partición de evaluación externa ciega, ACP sufrió un colapso masivo en su capacidad de evasión, contrayendo su EER degradado a un marginal 2.49%.

Por el contrario, el modelo **PKI demostró una resiliencia estructural superior** al sostener un EER degradado del 8.20% y elevar el costo del sistema global a un min t-DCF de 0.210 en validación externa OOD, consolidándose como la política de ataque más destructiva y robusta mediante los siguientes fundamentos empíricos y teóricos:

- **Regularización Coercitiva del Espacio de Acciones:** A diferencia de la aproximación estática y libre de ACP, PKI introduce restricciones físicas explícitas en las acciones continuas del procesador digital de señales (DSP), acotando las modificaciones de jitter y shimmer a medias realistas de -0.84 y -0.77. Esta inyección de conocimiento previo actúa como un regularizador matemático implícito sobre el gradiente del algoritmo PPO, impidiendo que el optimizador descubra atajos heurísticos numéricos o transformaciones destructivas triviales (firmas autolíticas) que, si bien son altamente recompensadas en el simulador local, resultan fácilmente detectables en la representación latente de una red congelada externa.

- **Eficiencia Asintótica en el Muestreo de Gradientes:** La incorporación de conocimiento acústico a priori resolvió el problema del arranque en frío (cold start), reduciendo drásticamente la entropía de exploración inicial. Esto permitió al agente PKI estabilizar una política generalizable en apenas 143,360 pasos de entrenamiento (una convergencia un 30% más rápida en comparación con el modelo Base y un 78.1% más eficiente en cómputo que los 655,360 pasos requeridos por ACP), demostrando que delimitar el espacio de búsqueda incrementa la densidad de actualización útil por gradiente.

- **Evasión de Pozos de Gravedad y Preservación de la Entropía:** Al no depender de la asignación suave de clústeres acústicos variables del espacio latente, PKI no sufre el desplome asimétrico de entropía o colapso de modo (mode collapse) observado en ACP (cuya entropía de Shannon normalizada se redujo en un 52%, concentrando el 87.11% de su éxito en menos del 3% del conocimiento original de la red). La perturbación inyectada por PKI opera como un ataque de alta entropía espectral distribuyendo su energía de manera uniforme; esto le permite transitar y vulnerar las fronteras de decisión de AASIST3 sin quedar atrapado en la paradoja de la generalización local, donde el agente RL abandona voluntariamente subespacios robustos (como el Clúster 2 en inferencia libre) para priorizar recompensas codiciosas de corto alcance.

8.2 Deconstrucción de la "Ilusión del ASR"

Un descubrimiento metodológico clave de esta tesis es la profunda disparidad inherente entre las métricas de rendimiento locales optimizadas dentro de un Proceso de Decisión de Markov (MDP) de entrenamiento y la resiliencia real demostrada ante un clasificador del estado del arte en un marco de evaluación cerrado y fuera de distribución (OOD). Durante la fase de entrenamiento interactivo, los agentes lograron optimizar políticas locales que alcanzaron un Attack Success Rate (ASR) nominal superior al 78% (llegando al 91,45% en el caso de ACP). Sin embargo, al congelar los pesos y evaluar a los agentes sobre el conjunto de validación cerrado, la vulnerabilidad real infligida reveló la fragilidad de esta optimización.

El agente BASE constituye el paradigma de esta ilusión. A pesar de registrar un progreso inicial en entrenamiento (EER=18,45%), al ser expuesto a la partición externa OOD bajo el clasificador defensivo AASIST3, arrojó un EER degradado del 0,00% (lo que equivale a un fracaso absoluto

del ataque al no incrementar en absoluto la tasa de error del detector). Al operar sin penalizaciones acústicas condicionadas ni regularización de recompensa, el optimizador PPO sacrificó la integridad física de la señal de audio en favor de atajos numéricos locales del simulador. Al eliminar rasgos espectrales fundamentales y forzar un colapso del jitter y shimmer a mínimos teóricos no realistas, el agente generó una firma acústica artificialmente simplificada (firma autolítica) que resultó trivialmente detectable para la representación latente de AASIST3. Este fenómeno subraya la invalidez del ASR interno del MDP como métrica de bioseguridad y justifica la necesidad de utilizar el binomio EER degradado / min t-DCF como único estándar de auditoría adversarial.

8.3 Covariate Shift y Vulnerabilidad por Dispersión (Sobreajuste Local)

Para demostrar por qué el agente ACP tuvo éxito en test (Tabla 2), se contrastó la densidad de muestras de su ataque frente a la densidad de la distribución de entrenamiento original de AASIST3 ($N_{train} = 22800$).

Cluster ID	Proporción en Train AASIST3 (%)	Proporción en Ataque ACP (%)	Dinámica del Subespacio de Voz
0, 3, 8	~ (Combinados)	0,00%	Núcleo Acústico Denso **⟶ Inmune al ataque**
1	**3,64%**	11,79%	Subespacio de Fricción
5	0,53%	**61,51%**	Variedad Dispersa **⟶ Ruta de Evasión Primaria**
7	2,33%	25,60%	Variedad Dispersa **⟶ Ruta de Evasión Secundaria**

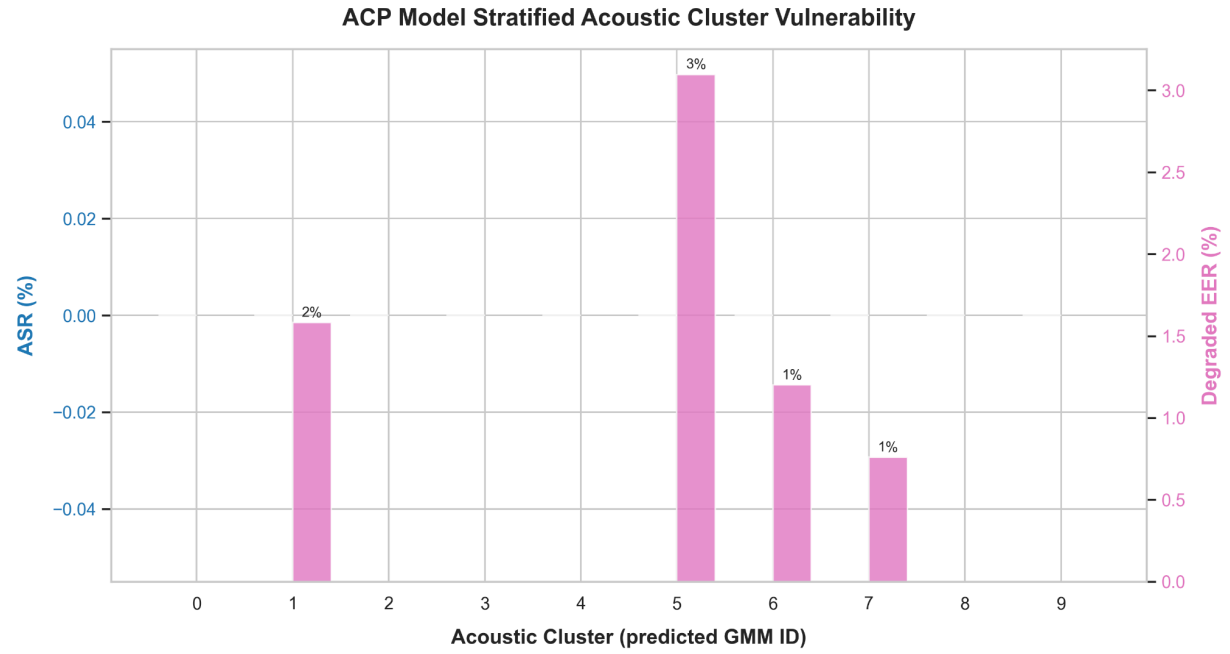
Tabla 5: Densidad de Manifolds (Entrenamiento Original vs. Ataque Generado).

Los clusteres densos y fuertemente representados en el entrenamiento de AASIST3 (0, 3 y 8) poseen fronteras de decisión extremadamente robustas y regularizadas, rechazando el 100% de los ataques.

Para lograr la evasión general, la política PPO ejecutó un brutal desplazamiento de covariables (*covariate shift*). Forzó la proyección geométrica de las señales sobre los **Clusteres 5 y 7**. El Cluster 5, que representaba apenas un marginal 0,53% en el historial de AASIST3, fue sobre-explotado hasta constituir el 61,51% de las evasiones exitosas.

El 87,11% del éxito destructivo del agente se concentró en variedades acústicas que representan menos del 3% del conocimiento original de la red. Esto revela que las redes

profundas sufren de **sobreajuste local**: los vacíos de densidad en el conjunto de entrenamiento crean corredores latentes no regularizados por los cuales un agente DSP puede transitar encubierto.



8.4 Entropía de Shannon y Colapso de Modo de la Política (Mode Collapse)

Analizamos la Entropía de Shannon Normalizada (H_{norm}) sobre los 10 componentes del GMM para cuantificar la diversidad:

$$H(X) = -\sum_{i=0}^{N-1} P(x_i)\log_2 P(x_i) \qquad H_{\text{norm}} = \frac{H(X)}{\log_2 N}$$

El conjunto de entrenamiento de referencia posee una distribución equilibrada (0,8640). Sin embargo, las acciones adversariales generadas por el agente ACP sufrieron un desplome asimétrico (0,4145).

Esta caída matemática del 52% define un severo **colapso de modo** (*mode collapse*). PPO sacrificó vectores adversariales universales a favor del "camino de menor resistencia". Al notar que los clusteres raros 5 y 7 constituían *Optimization Gravity Wells* altamente recompensados, convergió determinísticamente hacia dichos atajos subrepresentados.

8.5 La Paradoja de Generalización (Zero-Shot vs. Ejecución Libre)

La confirmación matemática de este colapso se manifiesta al contrastar las distintas etapas experimentales de la investigación. Durante la fase de desarrollo cerrado, al aislar los clústeres altamente vulnerables y forzar metodológicamente al agente ACP a operar exclusivamente

sobre el Clúster 2 (completamente excluido del cálculo de gradientes), el modelo demostró una notable capacidad de transferencia latente (Zero-Shot), registrando un ASR inmediato del 12,88% sobre una subpoblación de 80 muestras.

Excluir el Clúster 5 del entrenamiento para mitigar su dominancia inicial y evitar el sesgo prematuro del optimizador demostró ser una decisión de diseño acertada. Sin embargo, al liberar al agente ACP en un entorno de evaluación global OOD sin restricciones de enrutamiento, la explotación sobre el Clúster 2 decayó a un absoluto 0,00% local. Esto revela una paradoja fundamental en el modelado adversarial mediante RL: el agente posee internamente la capacidad arquitectónica para generalizar perturbaciones sutiles sobre variedades acústicas complejas y regularizadas; no obstante, el mecanismo de maximización de recompensa codicioso del algoritmo PPO lo induce a abandonar voluntariamente estas estrategias generalizables en favor de heurísticas de explotación local simplificadas dentro de los corredores vulnerables (clusters 5 y 7).

9. Conclusiones

El marco experimental de KON-Artist ha probado de forma rigurosa que las fronteras de decisión no lineales en biometría de voz profunda (AASIST3) resultan estructuralmente vulnerables a ataques adversariales continuos en el dominio del procesamiento de señales.

A través de la integración de Inyección de Conocimiento Previo (PKI) y el control topológico de Políticas Condicionadas por Acústica (ACP), el *framework* no solo superó el estancamiento histórico de los gradientes, sino que expuso el mecanismo subyacente de la falla. Los ataques no triunfan por generar audios indistinguibles a nivel universal, sino por comportarse como buscadores de anomalías geométricas: el agente de Aprendizaje por Refuerzo explota el sobreajuste local del clasificador, ejecutando colapsos de modo severos (reducción de la entropía de la política) para canalizar el vector de perturbación adversarial de su *payload* sobre clusteres marginados (que representan apenas una fracción marginal de los datos originales).

La identificación de esta dinámica de "pozos de gravedad de optimización" redefine los protocolos de auditoría, descalificando al ASR interno como métrica confiable y estableciendo que el aseguramiento robusto de sistemas biométricos requerirá indispensablemente un monitoreo de dispersión latente (MBAT y OOD Gating).

Recomendaciones Defensivas para Sistemas Anti-Spoofing

Entrenamiento Adversarial Balanceado por Variedad (MBAT):

Se debe sobre-muestrear sintéticamente o aplicar perturbaciones adversariales *únicamente* sobre aquellas variedades de baja densidad (como los Clusteres 5 y 7), densificando artificialmente las regiones de decisión más frágiles y penalizando el sobreajuste local.

Filtrado de Variedad Out-of-Distribution (OOD Gating)

Los sistemas en producción deben implementar un **Módulo de Enrutamiento Acústico en Línea**. Si la proyección del embedding latente recae sobre una variedad extremadamente subrepresentada en el historial de la red, el sistema debe invocar rutinas secundarias o rechazar la entrada precautoriamente, neutralizando el desplazamiento de covariables.

10. Trabajo Futuro

Para superar las limitaciones técnicas identificadas y avanzar en el desarrollo de atacantes realistas y defensas robustas para sistemas biométricos de voz, se definen las siguientes líneas estratégicas de investigación:

Dimensión de Acción: Ataques de *Partial Spoofing* y Atenuación Temporal

Los modelos actuales asumen de manera implícita la presencia de artefactos sintéticos distribuidos de forma homogénea a lo largo del audio. Sin embargo, los despliegues de fraude real suelen utilizar ataques de *Partial Spoofing*, donde se interpolan segmentos sintéticos dentro de un flujo de habla natural. El trabajo futuro apuntará a extender el espacio de acciones del agente de RL para que aprenda a optimizar máscaras de atenuación temporalmente localizadas, maximizando la evasión sin degradar el habla legítima circundante.

Dimensión de Modelado: Regularización y Clusterización Acústica Avanzada (WavLM/XLS-R)

El desajuste en la distribución de clusteres limitó la generalización plena de la política ACP. Se propone sustituir los GMM basados en características espectrales nativas por *embeddings* extraídos de modelos de voz autosupervisados de última generación. Asimismo, se planea integrar algoritmos de balanceo activo en el búfer de experiencia de RL (ej. *Prioritized Experience Replay* condicionado por cluster) para obligar a la política a explorar de manera uniforme todas las variedades, neutralizando el colapso temprano de modo.

Dimensión de Simulación Física: Procesamiento Digital de Señales (DSP) y Simulación Acústica de Respuesta al Impulso de la Sala (RIR)

Las transformaciones aplicadas en este estudio representan un canal de transmisión digital directo. Para evaluar la transferibilidad a escenarios *over-the-air* reales, se debe desarrollar un entorno de simulación acústica diferenciable. La inyección dinámica de funciones de transferencia de sala (RIR) y ruido ambiental obligará al agente de RL a optimizar ataques adversariales que sean robustos frente a la distorsión severa del canal físico real.